

Московский государственный технический университет им. Н.Э. Баумана

Факультет «Информатика и системы управления»

Кафедра ИУ5 «Системы обработки информации и управления»

Курс «Технологии машинного обучения»

Отчет по рубежному контролю

«Технологии разведочного анализа и обработки данных»

Вариант 6

```
In [10]: import pandas as pd
import warnings
warnings.filterwarnings("ignore")
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
```

```
In [3]: df = pd.read_csv('Admission_Predict.csv')
```

```
In [4]: df.head()
```

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	Chance of Admit	
0	1	337	118	4	4.5	4.5	9.65	1	0.92	
1	2	324	107	4	4.0	4.5	8.87	1	0.76	
2	3	316	104	3	3.0	3.5	8.00	1	0.72	
3	4	322	110	3	3.5	2.5	8.67	1	0.80	
4	5	314	103		2	2.0	3.0	8.21	0	0.65

```
In [5]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 400 entries, 0 to 399
Data columns (total 9 columns):
 #   Column           Non-Null Count  Dtype  
--- 
 0   Serial No.        400 non-null    int64  
 1   GRE Score         400 non-null    int64  
 2   TOEFL Score       400 non-null    int64  
 3   University Rating 400 non-null    int64  
 4   SOP                400 non-null    float64 
 5   LOR                400 non-null    float64 
 6   CGPA               400 non-null    float64 
 7   Research            400 non-null    int64  
 8   Chance of Admit    400 non-null    float64 
dtypes: float64(4), int64(5)
memory usage: 28.2 KB
```

```
In [6]: df = df.drop(['Serial No.'], axis=1)
df.isnull().sum()
```

```
Out[6]: GRE Score      0
TOEFL Score      0
University Rating 0
SOP              0
LOR              0
CGPA             0
Research          0
Chance of Admit  0
dtype: int64
```

```
In [19]: fig = sns.boxplot(df['GRE Score'])
plt.show()



fig = sns.boxplot(df['TOEFL Score'])
plt.show()



fig = sns.boxplot(df['University Rating'])
plt.show()


fig = sns.boxplot(df['SOP'])
plt.show()

fig = sns.boxplot(df['CGPA'])
plt.show()


plt.show()
```








```
In [7]: fig = sns.regplot(x="GRE Score", y="TOEFL Score", data=df)
plt.title("GRE Score vs TOEFL Score")
plt.show()
```



Люди с более высокими баллами GRE также имеют более высокие баллы TOEFL, что оправдано, тк они связаны между собой (хоть и косвенно)

- GRE — тест, который необходимо сдавать для поступления в аспирантуру, магистратуру или иной последипломный курс в вузе США и ряда других стран.
- TOEFL — стандартизованный тест на знание английского языка, результаты которого могут использоваться для подтверждения уровня владения английским языком абитуриентами из неанглоязычных стран при поступлении в вузы США, а также Европы и Азии.


```
In [8]: fig = sns.regplot(x="GRE Score", y="CGPA", data=df)
plt.title("GRE Score vs CGPA")
plt.show()
```



Люди с более высоким CGPA обычно имеют более высокие баллы GRE

- Система оценивания знаний — система оценивания качества освоения образовательных программ учащимся, важнейший элемент образовательного процесса.

```
In [15]: corr = df.corr()
sns.heatmap(corr, linewidths=.5, annot=True, fmt=".2f")
plt.show()
```



- 1) С целевым признаком "Chance of Admit" наиболее коррелируют признаки "CGPA", "GRE Score", , "TOEFL Score". При построении модели машинного обучения перечисленные признаки будут наиболее информативными.
- 2) Стоит отметить корреляцию признаков "SOP" и "University Rating".
- 3) Можно построить модель машинного обучения на основе признаков "CGPA", "GRE Score", "TOEFL Score", "LOR", "Research". Первые 3 признака наиболее сильно влияют на результат ввиду их высокой корреляции. Обученные модели позволят бакалаврам оценить свои возможности для поступления на магистратуру.